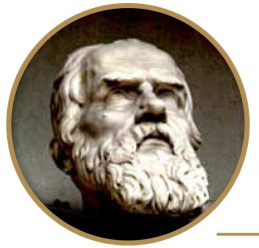

Galileo UNIVERSIDAD
La Revolución en la Educación

Proyecto Final
Ciencia de Datos en Python
Postgrado en Análisis y Predicción de Datos

SAUL ALEXANDER LÓPEZ CONTRERAS 24000138

JOSIAS EMANUEL CHOCOOJ AZMITIA 24000705

ERICK MANUEL ANDRADE ZUÑIGA 24000165

Introducción

Desarrollo de sistema de ingeniería de datos, empleando:

- AWS, desarrollo infraestructura transaccional
- SQL, proceso de ETL, para carga de datos
- Python, principal sistema de programación para desarrollo de los insumos del proyecto

Objetivos

General

- Desarrollo de sistema transaccional, integrando Python, AWS y SQL.

Específicos

- Implementar un sistema transaccional automatizado en AWS.
- Crear y poblar una base de datos utilizando Python.
- Diseñar y construir un data warehouse que responda a preguntas de negocio específicas.
- Desarrollar un proceso ETL para integrar, transformar y cargar datos.
- Realizar análisis de datos y visualización para responder a preguntas de negocio.

Infraestructura

Desarrollada en AWS
- Amazon RDS
- Amazon EC2

Base de datos
- Transaccional: MySQL
- DataWarehouse: PostgreSQL
- Carga de datos: Faker

ETL
- Carga de dimensiones: pandas

Análisis de preguntas de negocio
- Carga de dimensiones: pandas, matplotlib, seaborn

RDS

EC2

Código

Crear Bases de datos Transaccional y DataWarehouse

```python
# Crear la base de datos MySQL de transacciones
try:
    response = aws_rds_conn.create_db_instance(
        DBInstanceIdentifier=config.get('TRANSACC', 'DB_INSTANCE_ID'),
        DBName=config.get('TRANSACC', 'DB_NAME'),
        DBInstanceClass='db.t2.micro',
        Engine='mysql',
        MasterUsername=config.get('TRANSACC', 'DB_USER'),
        MasterUserPassword=config.get('TRANSACC', 'DB_PASSWORD'),
        Port=int(config.get('TRANSACC', 'DB_PORT')),
        PubliclyAccessible=True,
        VpcSecurityGroupIds=[config.get('VPC', 'SECURITY_GROUP')],
        AllocatedStorage=20
    )
    print(response)
except aws_rds_conn.exceptions.DBInstanceAlreadyExistsFault as ex:
    print("La instancia de base de datos MySQL ya existe.")
except Exception as ex:
    print("Error al crear la base de datos MySQL:", ex)
```

```python
# Crear la base de datos PostgreSQL para DWH
try:
    response = aws_rds_conn.create_db_instance(
        DBInstanceIdentifier=config.get('DWH', 'DB_INSTANCE_ID'),
        DBName=config.get('DWH', 'DB_NAME'),
        DBInstanceClass='db.t2.micro',
        Engine='postgres',
        MasterUsername=config.get('DWH', 'DB_USER'),
        MasterUserPassword=config.get('DWH', 'DB_PASSWORD'),
        Port=int(config.get('DWH', 'DB_PORT')),
        PubliclyAccessible=True,
        VpcSecurityGroupIds=[config.get('VPC', 'SECURITY_GROUP')],
        AllocatedStorage=20
    )
    print(response)
except aws_rds_conn.exceptions.DBInstanceAlreadyExistsFault as ex:
    print("La instancia de base de datos PostgreSQL ya existe.")
except Exception as ex:
    print("Error al crear la base de datos PostgreSQL:", ex)
```

Ingesta de datos

```
from sqlalchemy import create_engine, Column, Integer, String, DECIMAL, DateTime, ForeignKey
from sqlalchemy.ext.declarative import declarative_base
from sqlalchemy.orm import sessionmaker, relationship
from faker import Faker
import random

db_url = 'mysql+pymysql://root:password@localhost/transactional_db'
engine = create_engine(db_url)
Session = sessionmaker(bind=engine)
session = Session()
Base = declarative_base()

fake = Faker()
```

Crear dimensiones

```python
from sqlalchemy import create_engine, Column, Integer, String, Numeric, DateTime, ForeignKey
from sqlalchemy.ext.declarative import declarative_base
from sqlalchemy.orm import sessionmaker, relationship

db_url = 'postgresql://usuario:contraseña@localhost/dwh_db'
engine = create_engine(db_url)
Session = sessionmaker(bind=engine)
session = Session()
Base = declarative_base()

# Tabla de dimensión para Categoría (SCD Tipo 1)
class DimCategoria(Base):
    __tablename__ = 'dim_categoria'
    idcategoria = Column(Integer, primary_key=True)
    nombre = Column(String(50))
    descripcion = Column(String(255))
    estado = Column(Integer)
    fecha_inicio = Column(DateTime)
    fecha_fin = Column(DateTime)

    def __repr__(self):
        return f"<DimCategoria(idcategoria={self.idcategoria}, nombre='{self.nombre}')>"
```

Proceso ETL

```python
# Extracción, transformación y carga de la dimensión Categoría
def etl_dim_categoria():
    # Extracción
    df_categoria = pd.read_sql('SELECT * FROM categoria', transactional_engine)

    # Transformación
    df_categoria_dim = df_categoria.rename(columns={'idcategoria': 'idcategoria', 'nombre': 'nombre',
'descripcion': 'descripcion', 'estado': 'estado'})
    df_categoria_dim['fecha_inicio'] = pd.to_datetime('today')
    df_categoria_dim['fecha_fin'] = pd.to_datetime('2999-12-31')

    # Carga
    df_categoria_dim.to_sql('dim_categoria', dwh_engine, if_exists='append', index=False)
```

Preguntas de negocio

¿Cuál es el total de ventas por categoría de art ículo en un período específico?

Comparativa de las ventas totales, por categoría de artículo en 2023.

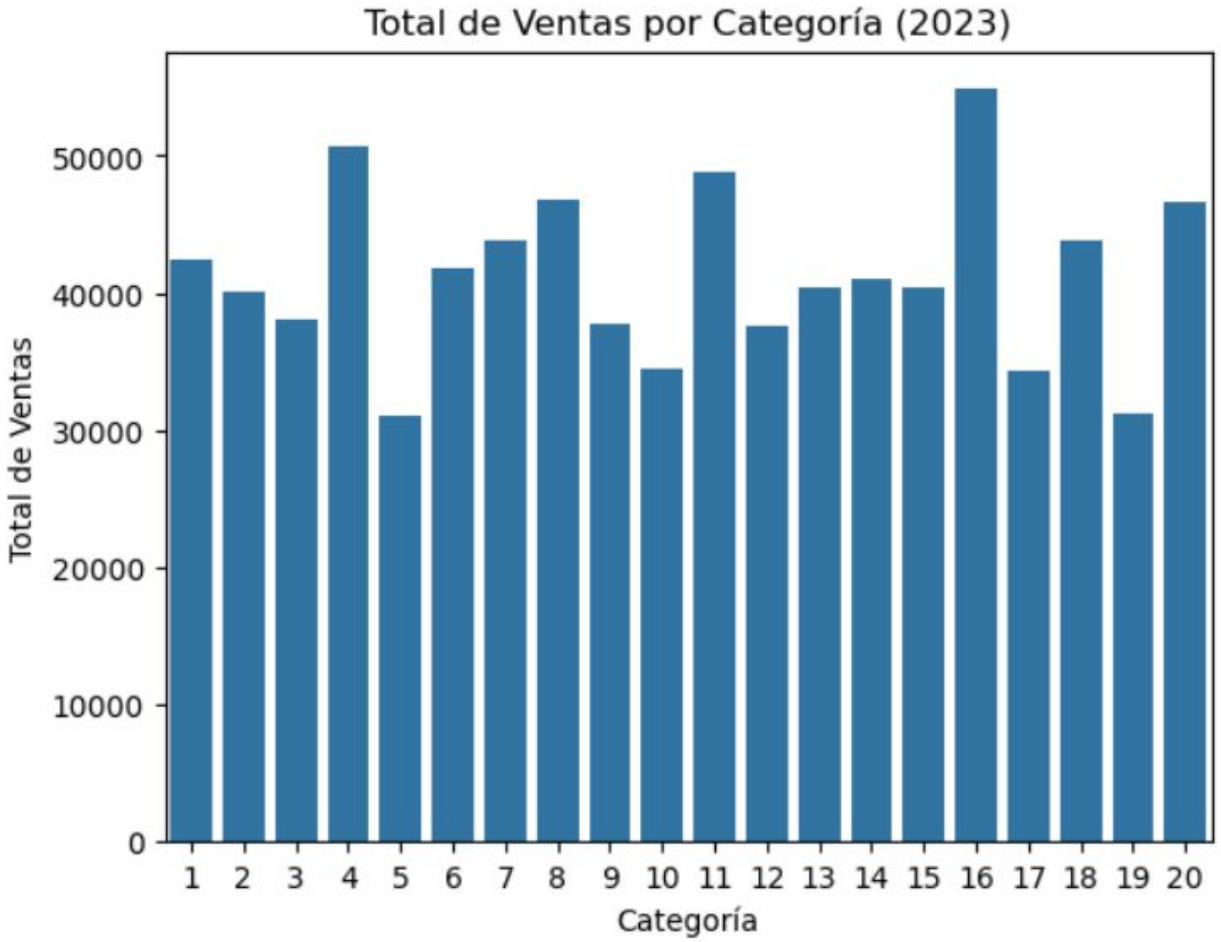

Código visualización

```
sns.barplot(x='idcategoria', y='precio', data=ventas_por_categoria)
plt.xlabel('Categoría')
plt.ylabel('Total de Ventas')
plt.title('Total de Ventas por Categoría (2023)')
plt.show()
```

¿Quiénes son los clientes que generan el mayor volumen d e ventas y cuál es su contribución al total de ingresos?

Comparativa de clientes de acuerdo con cantidad de ventas que se les realizaron, orden descendente.

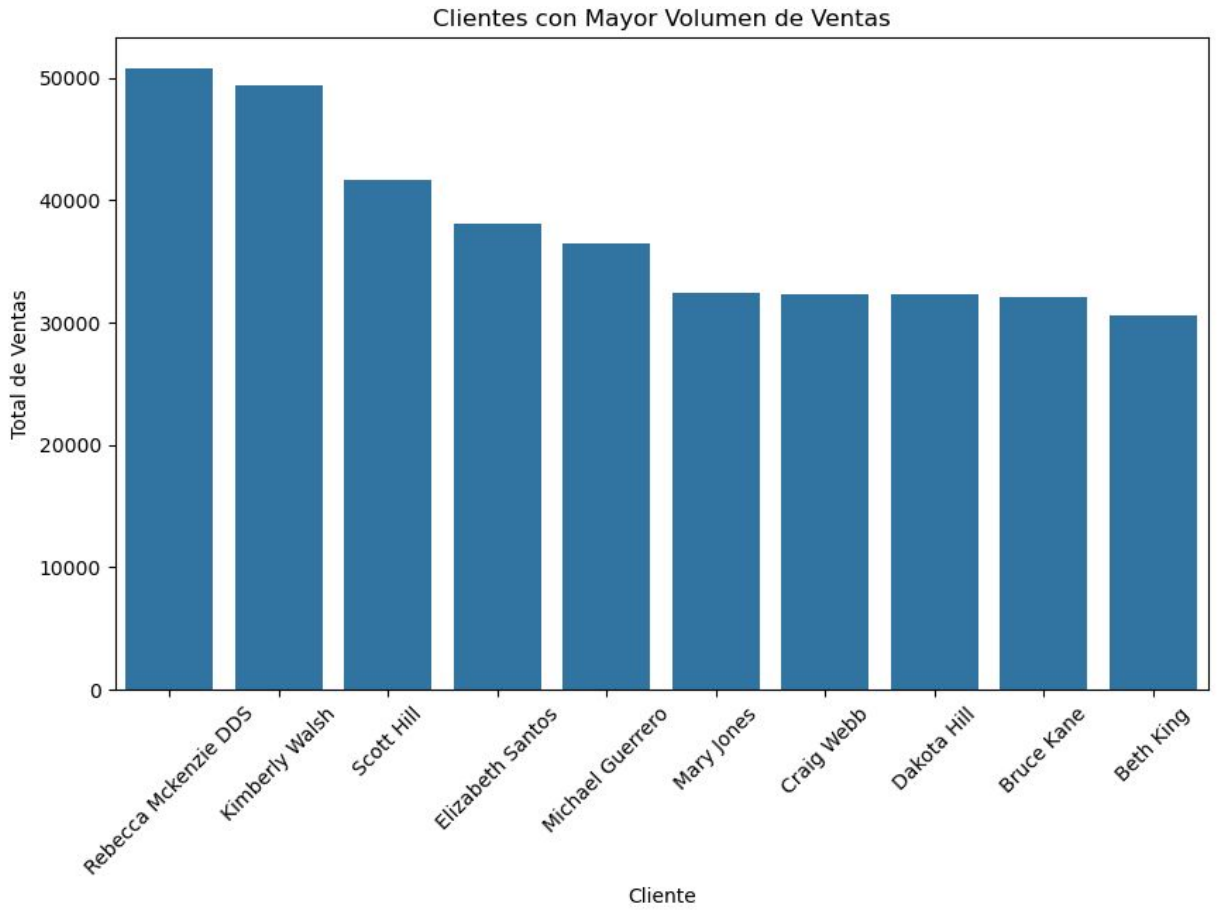

Código visualización

```
plt.figure(figsize=(10, 6))
sns.barplot(x='nombre', y='total', data=ventas_por_cliente.head(10))
plt.xlabel('Cliente')
plt.ylabel('Total de Ventas')
plt.title('Clientes con Mayor Volumen de Ventas')
plt.xticks(rotation=45)
plt.show()
```

¿Cuál es el rendimiento de ventas de cada vendedor y cómo se compara con el promedio de ventas por vendedor?

Comparativa de vendedores totales, por ventas obtenidas. Se identifica promedio de ventas, para destacar vendedores por encima del promedio.

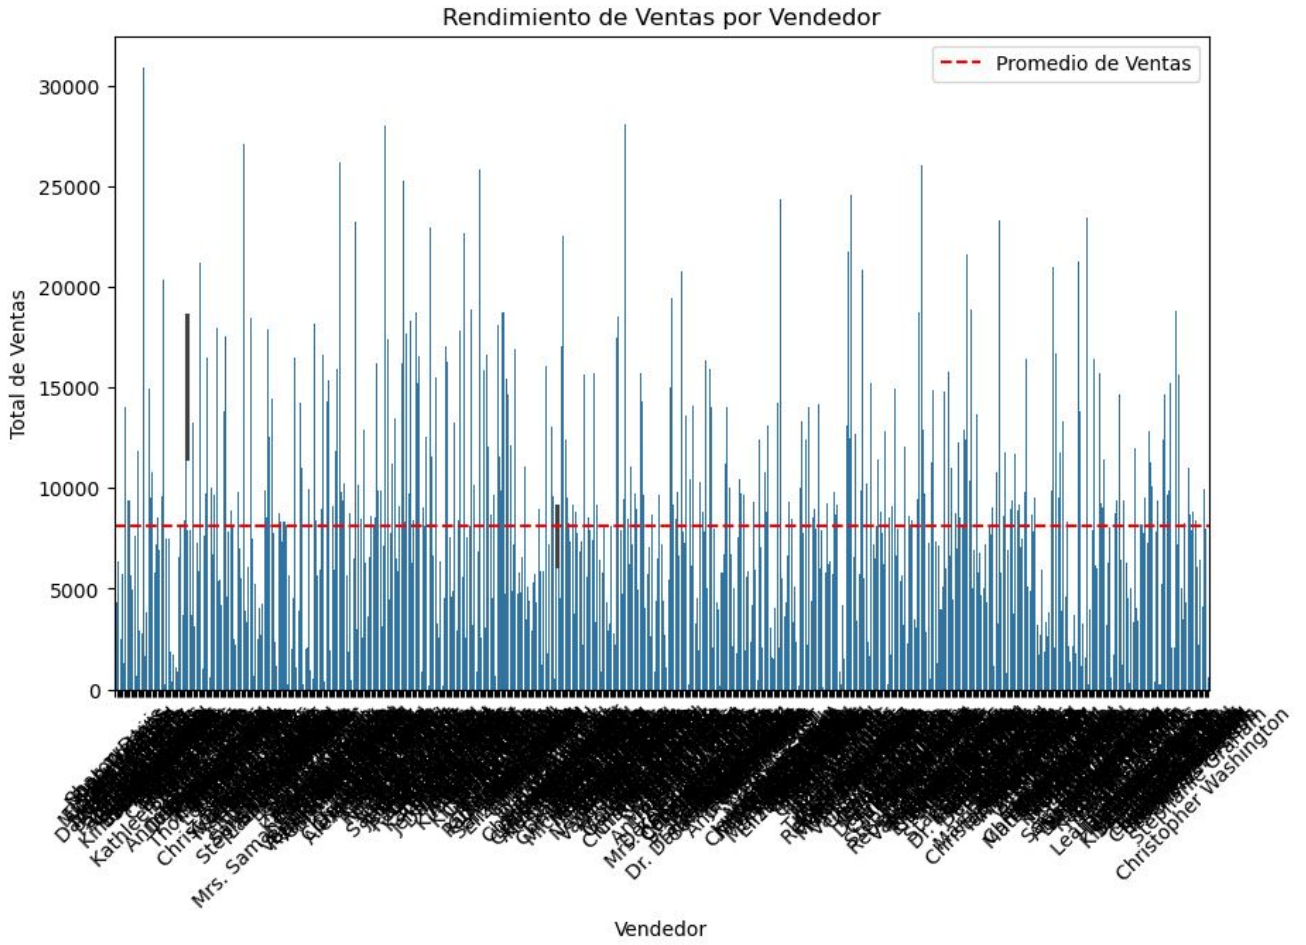

Código visualización

```
plt.figure(figsize=(10, 6))
sns.barplot(x='nombre', y='total', data=ventas_por_vendedor)
plt.axhline(promedio_ventas, color='red', linestyle='--', label='Promedio de Ventas')
plt.xlabel('Vendedor')
plt.ylabel('Total de Ventas')
plt.title('Rendimiento de Ventas por Vendedor')
plt.xticks(rotation=45)
plt.legend()
plt.show()
```

¿Cuáles son los artículos más vendidos y menos vendidos en términos de cantidad y monto total de ventas?

Detalle de artículos con mayor y menor cantidad de ventas.

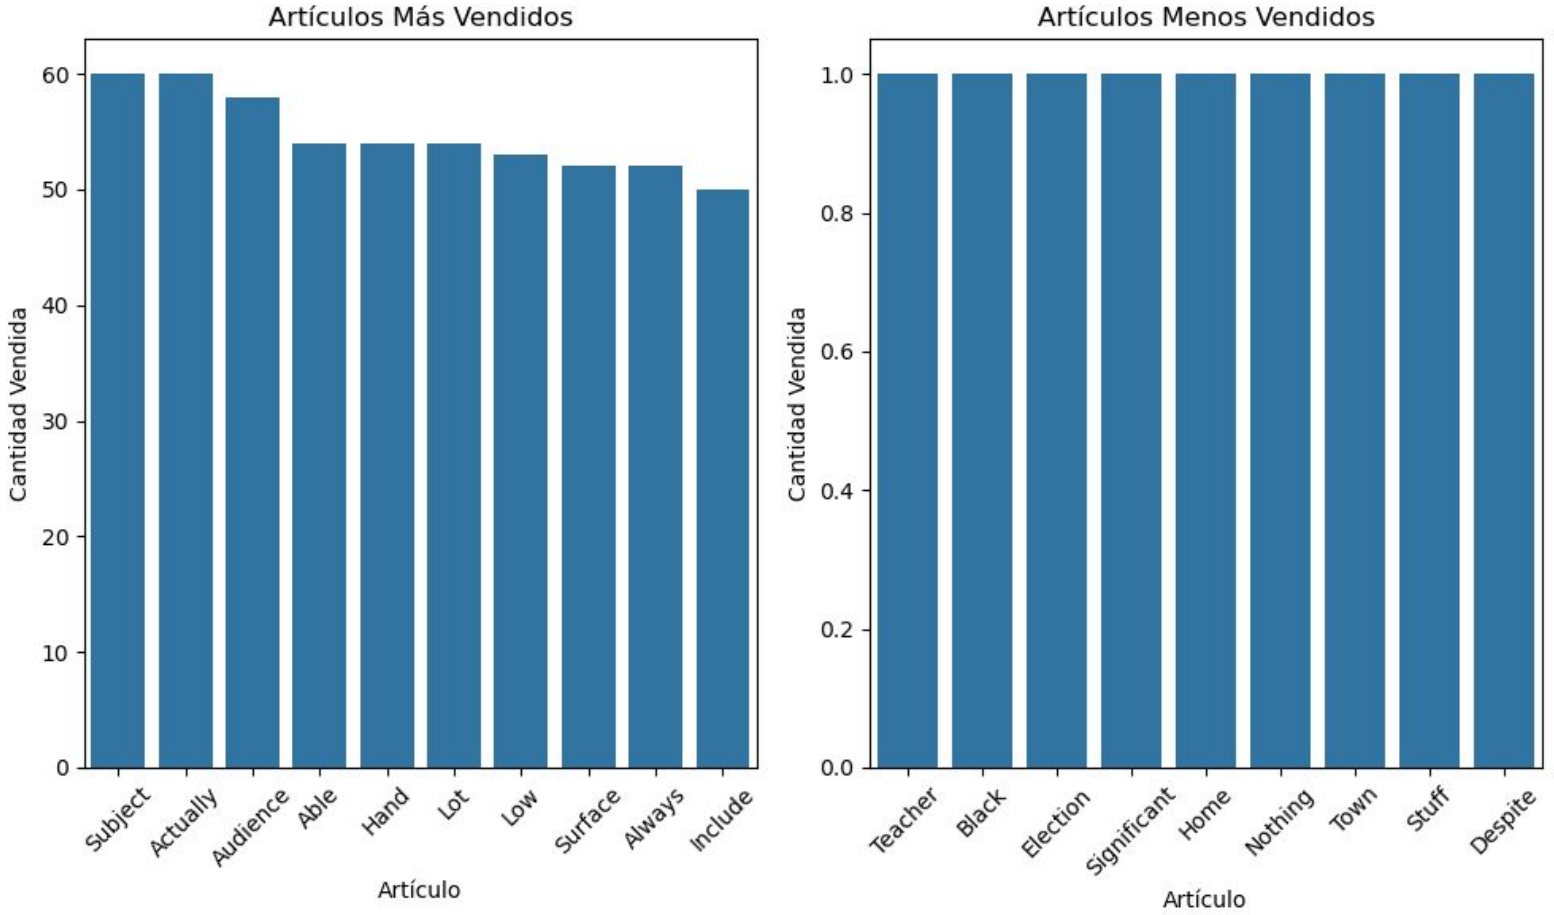

Código visualización

```
plt.figure(figsize=(10, 6))
plt.subplot(1, 2, 1)
sns.barplot(x='nombre', y='cantidad', data=articulos_mas_vendidos)
plt.xlabel('Artículo')
plt.ylabel('Cantidad Vendida')
plt.title('Artículos Más Vendidos')
plt.xticks(rotation=45)

plt.subplot(1, 2, 2)
sns.barplot(x='nombre', y='cantidad', data=articulos_menos_vendidos)
plt.xlabel('Artículo')
plt.ylabel('Cantidad Vendida')
plt.title('Artículos Menos Vendidos')
plt.xticks(rotation=45)

plt.tight_layout()
plt.show()
```

¿Cómo ha evolucionado el volumen de ventas a lo lar go del tiempo (por mes, trimestre, año)?

Tendencia de ventas a lo largo del tiempo, por mes, trimestre y año.

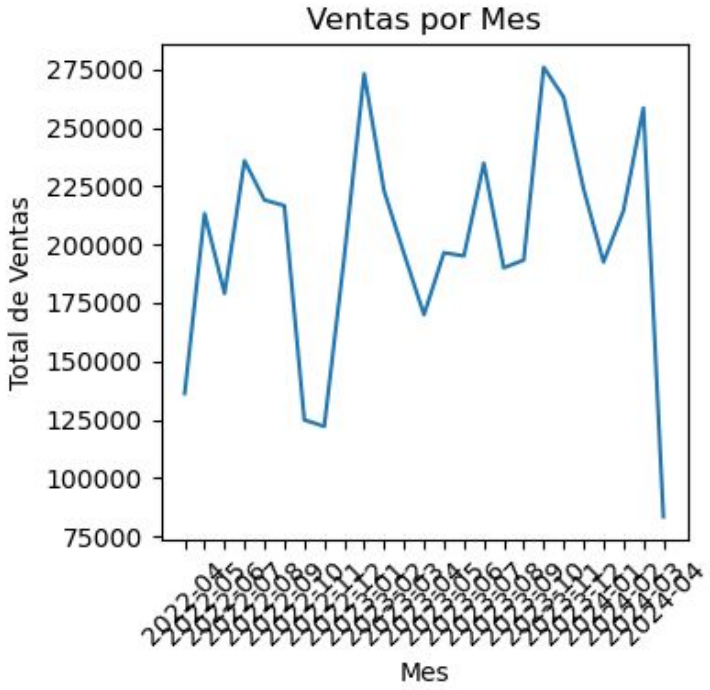

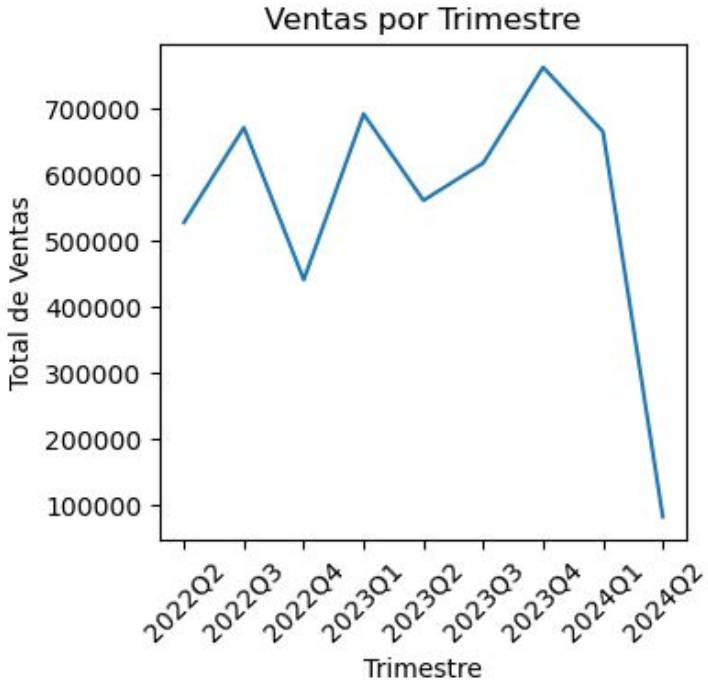

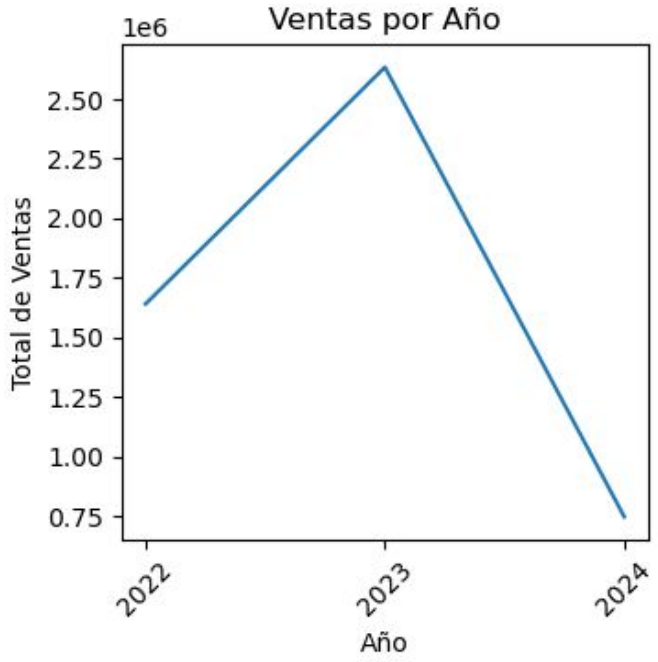

Código visualización

```
plt.figure(figsize=(12, 4))

plt.subplot(1, 3, 1)
sns.lineplot(x='mes', y='ventas', data=ventas_por_mes)
plt.xlabel('Mes')
plt.ylabel('Total de Ventas')
plt.title('Ventas por Mes')
plt.xticks(rotation=45)

plt.subplot(1, 3, 2)
sns.lineplot(x='trimestre', y='ventas', data=ventas_por_trimestre)
plt.xlabel('Trimestre')
plt.ylabel('Total de Ventas')
plt.title('Ventas por Trimestre')
plt.xticks(rotation=45)
```

```
plt.subplot(1, 3, 3)
sns.lineplot(x='año', y='ventas', data=ventas_por_anio)
plt.xlabel('Año')
plt.ylabel('Total de Ventas')
plt.title('Ventas por Año')
plt.xticks(rotation=45)

plt.tight_layout()
plt.show()
```

Conclusiones

- El proyecto de ingeniería de datos alcanzó con éxito sus objetivos, desarrollando un pipeline eficiente utilizando Python, SQL, y AWS que mejoró significativamente la capacidad de análisis y toma de decisiones basadas en datos dentro de la organización.

- Las soluciones adoptadas han enriquecido el conocimiento técnico del equipo y han establecido una base sólida para futuras mejoras y escalabilidad del sistema. Esto reitera la importancia de la adaptabilidad y el aprendizaje continuo en el campo de la ciencia de datos y la ingeniería de sistemas.